# 以 CRISP-DM 進行線性回歸分析

單純 / 多元線性回歸・Auto Regression｜兩個 Kaggle 資料集｜預測附 95% 信賴與預測區間

① 業務理解 Business | ② 資料理解 Data | ③ 資料準備 Preparation | ④ 建模 Modeling | ⑤ 評估 Evaluation | ⑥ 部署 Deployment

## 資料集

### Bike Sharing（每日租借量）

來源：Kaggle / UCI・CC BY 4.0

| 731 | 14 | cnt |
|---|---|---|
| 筆（天） | 個特徵 | 目標變數 |

### King County 房價

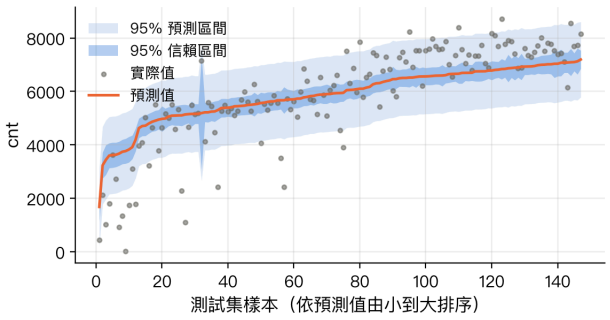
來源：Kaggle・CC0: Public Domain

| 21,613 | 19 | price |
|---|---|---|
| 筆交易 | 個特徵 | 目標變數 |

## 最佳模型與關鍵指標（測試集）

**Bike**：多元線性回歸（全部 28 個特徵）

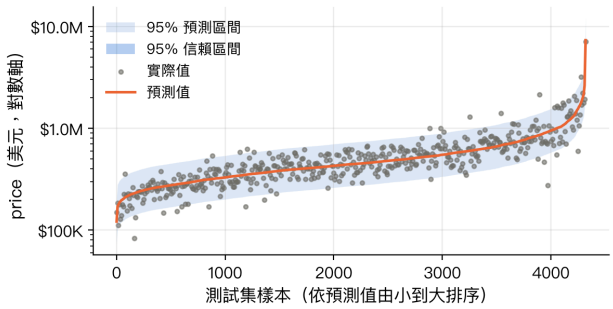
| 0.654 | 1,103 |
|---|---|
| $R^2$ | RMSE（次） |




深色帶＝信賴區間，淺色帶＝預測區間

**House**：多元線性回歸（全部 28 個特徵）

| 0.764 | $174,728 |
|---|---|
| $R^2$（log 尺度） | RMSE（美元） |




對數軸；轉回美元後區間上寬下窄

## 特徵選擇重點（相關係數 → VIF → 逐步回歸）

**28 → 21**

候選特徵 → 最終特徵

Bike：VIF 移除 temp、mnth_7

**28 → 20**

候選特徵 → 最終特徵

House：VIF 移除 sale_year

- Bike 移除 casual、registered（相加＝cnt，**資料洩漏**）
- Bike 依時間切分 80/20，不偷看未來
- House 以 log(price) 建模，zipcode 改用經緯度

**https://supermlk.github.io/iot-hw2/**

互動網站：切換資料集、瀏覽 CRISP-DM 六步驟、比較模型預測圖，也能輸入任意 CSV 網址即時檢視資料。